Підготовка даних до аналізу

Мета

Ознайомитись з методикою первинної обробки даних. Після завершення цієї лабораторної роботи ви зможете:

- Досліджувати структуру завантажених даних
- Виправляти формати даних
- Знаходити та заповнювати пропуски в даних
- Знаходити викиди та некоректні значення
- Будувати прості візуалізації

Завдання, що оцінюються

1. Скачати дані із файлу, записати у dataframe. Дослідити структуру даних.
2. Виправити помилки в даних.
3. Побудувати діаграми розмаху та гістограми.
4. Заповнити пропуски.
5. Додати стовпчик із щільністю населення.

Завдання #1:

Дослідити структуру даних

Для того, щоб працювати з файлами, які зберігаються у хмарному сховищі, необхідно надати середовищу Google Colab доступ до Google Диску.

```
from google.colab import drive
drive.mount('/content/drive')
```

```
Drive already mounted at /content/drive; to attempt to forcibly remount, call drive.mount("/content/drive", force_remou
```

Наступним кроком імпортуємо бібліотеку Pandas, яка є основним інструментом для маніпуляцій з даними. Оскільки вихідний файл Data2.csv має специфічне кодування та розділювачі, ми вказуємо параметри encoding='cp1252' та sep=';' для коректного відображення символів і структури таблиці.

```
import pandas as pd
df = pd.read_csv('/content/drive/MyDrive/python1/Data2.csv', encoding='cp1252', sep=';')
```

▶ Натисніть тут, щоб побачити підказку

Досліджую структуру даних

Після завантаження необхідно перевірити правильність зчитування даних. Використовую метод head(), щоб переглянути перші рядки таблиці, та info(), щоб проаналізувати типи даних у кожному стовпці та виявити можливі пропуски.

```
df.head(10)
```

	Country Name	Region	GDP per capita	Populatiion	CO2 emission	Area
0	Afghanistan	South Asia	561,7787463	34656032.0	9809,225	652860
1	Albania	Europe & Central Asia	4124,98239	2876101.0	5716,853	28750
2	Algeria	Middle East & North Africa	3916,881571	40606052.0	145400,217	2381740
3	American Samoa	East Asia & Pacific	11834,74523	55599.0	NaN	200
4	Andorra	Europe & Central Asia	36988,62203	77281.0	462,042	470
5	Angola	Sub-Saharan Africa	3308,700233	28813463.0	34763,16	1246700
6	Antigua and Barbuda	Latin America & Caribbean	14462,17628	100963.0	531,715	440
7	Argentina	Latin America & Caribbean	12440,32098	43847430.0	204024,546	2780400
8	Armenia	Europe & Central Asia	3614,688357	2924816.0	5529,836	29740
9	Aruba	Latin America & Caribbean	NaN	104822.0	872,746	180

Подальші дії: New interactive sheet

```
df.info()
```

```
<class 'pandas.core.frame.DataFrame'>
RangeIndex: 217 entries, 0 to 216
Data columns (total 6 columns):
 #   Column          Non-Null Count  Dtype
---  ------          --------------  -----
 0   Country Name    217 non-null    object
 1   Region          217 non-null    object
 2   GDP per capita  190 non-null    object
 3   Populatiion     216 non-null    float64
 4   CO2 emission    205 non-null    object
 5   Area            216 non-null    object
dtypes: float64(1), object(5)
memory usage: 10.3+ KB
```

Для отримання повної статистичної картини набору даних використовую метод describe. Параметр include='all' дозволяє проаналізувати не лише числові показники, а й текстові дані, відображаючи кількість унікальних значень та найбільш частотні записи.

```
df.describe(include='all')
```

	Country Name	Region	GDP per capita	Populatiion	CO2 emission	Area
count	217	217	190	2.160000e+02	205	216
unique	217	7	190	NaN	202	212
top	Afghanistan	Europe & Central Asia	561,7787463	NaN	495,045	460
freq	1	58	1	NaN	2	3
mean	NaN	NaN	NaN	4.338952e+07	NaN	NaN
std	NaN	NaN	NaN	1.879574e+08	NaN	NaN
min	NaN	NaN	NaN	1.109700e+04	NaN	NaN
25%	NaN	NaN	NaN	7.900265e+05	NaN	NaN
50%	NaN	NaN	NaN	6.318988e+06	NaN	NaN
75%	NaN	NaN	NaN	2.380373e+07	NaN	NaN
max	NaN	NaN	NaN	1.960424e+09	NaN	NaN

Перегляд переліку назв усіх стовпців необхідний для перевірки коректності заголовків. Це дозволяє виявити зайві пробіли або орфографічні помилки, які можуть заважати подальшому зверненню до даних.

```
df.columns
```

```
Index(['Country Name', 'Region', 'GDP per capita', 'Populatiion',
       'CO2 emission', 'Area'],
      dtype='object')
```

Одним із найважливіших етапів дослідження є виявлення пропущених значень. Використання комбінації методів isna() та sum() дозволяє швидко підрахувати кількість порожніх клітинок у кожному стовпці, що є важливим для прийняття рішення

про подальше очищення даних.

```
df.isna().sum()
```

	0
Country Name	0
Region	0
GDP per capita	27
Populatiion	1
CO2 emission	12
Area	1

dtype: int64

Оскільки такі показники, як площа країни чи її населення, фізично не можуть бути меншими за нуль, було проведено перевірку на наявність від'ємних значень.

```
df.apply(lambda col: col.astype(str).str.startswith('-').any(), axis=0)
```

	0
Country Name	False
Region	False
GDP per capita	True
Populatiion	False
CO2 emission	False
Area	True

dtype: bool

Щоб перевірити дані на наявність викидів, шукаю запис із максимальним значенням у певній категорії. Зокрема, пошук країни з найбільшим населенням дозволяє виявити потенційні помилки у розрядності чисел (наприклад, аномальні показники для невеликих країн).

```
df.loc[df['Populatiion'].idxmax()]
```

	108
Country Name	Latvia
Region	Europe & Central Asia
GDP per capita	14071,02723
Populatiion	1960424000.0
CO2 emission	6974,634
Area	64490

dtype: object

Бачу наступні проблеми в даних:

1. Ознаки GDP per capita, CO2 emission та Area мають тип object, хоча є кількісними показниками. Це унеможливлює проведення математичних розрахунків, оскільки числа сприймаються системою як рядки тексту.
2. Стовпець, що відповідає за кількість населення, має некоректну назву Populatiion (із зайвою літерою «i»). Це може спричинити помилки при зверненні до стовпця за його назвою в коді.
3. Наявні від’ємні значення в ознаках GDP per capita та Area.
4. Значення популяції для Латвії є некоректним.
5. Є пропущені значення в ознаках GDP per capita, Population, CO2 emission.

Завдання #2:

Виправити помилки в даних

Проблема 1. Неправильні назви

Використаю метод rename для виправлення орфографічної помилки у назві стовпця Populatiion (заміню на Population).

Перевіряю результат.

```
df = df.rename(columns={'Populatiion': 'Population'})
df.columns
```

```
Index(['Country Name', 'Region', 'GDP per capita', 'Population',
       'CO2 emission', 'Area'],
      dtype='object')
```

Проблема 2. Неправильні типи даних

Проаналізувавши df.info(), я бачу, що стовпці GDP per capita, CO2 emission та Area мають тип object замість float. Причиною є використання коми як роздільника десяткової частини числа, тоді як Python очікує крапку.

Для виправлення зроблю наступне:
1. Виберу проблемні стовпці.
2. Заміню в них усі коми на крапки за допомогою методу str.replace(',', '.').
3. Конвертую дані у числовий формат за допомогою pd.to_numeric.

Перевіряю результат.

```
cols_to_fix = ['GDP per capita', 'CO2 emission', 'Area']

for col in cols_to_fix:
    # errors='coerce' перетворить будь-яке "сміття", яке не є числом, на NaN
    df[col] = pd.to_numeric(df[col].astype(str).str.replace(',', '.'), errors='coerce')

print(df.dtypes)
```

```
Country Name       object
Region             object
GDP per capita    float64
Population        float64
CO2 emission      float64
Area              float64
dtype: object
```

Проблема 3. Неправильні значення (занадто великі або занадто малі)

Для виправлення від'ємних значень у стовпцях Area та GDP per capita я ввізьму ці числа за модулем (функція abs()), припускаючи, що це помилка знаку при введенні.
Населення Латвії вказано як приблизно 1.9 млрд, що у 1000 разів перевищує реальне. Це помилка розрядності, тому я поділю це значення на 1000.

Перевіряю результат.

```
cols_with_negatives = ['Area', 'GDP per capita']
for col in cols_with_negatives:
    df[col] = df[col].abs()

latvia_mask = (df['Country Name'] == 'Latvia') & (df['Population'] > 100000000)
if latvia_mask.any():
    df.loc[latvia_mask, 'Population'] = df.loc[latvia_mask, 'Population'] / 1000
    print("Населення Латвії виправлено.")

print(f"Мінімальна площа: {df['Area'].min()}")
print(f"Населення Латвії: {df.loc[df['Country Name'] == 'Latvia', 'Population'].values[0]}")
```

```
Населення Латвії виправлено.
Мінімальна площа: 0.0
Населення Латвії: 1960424.0
```

Додаткова перевірка на логічну цілісність: у стовпцях Area, Population та GDP per capita нуль є технічною помилкою. Я заміню всі нулі на NaN, щоб на наступному етапі вони були автоматично заповнені медіаною разом з іншими пропущеними значеннями. Це також може запобігти помилці ділення на нуль при розрахунку.

```
import numpy as np

cols_to_check_zeros = ['Area', 'Population', 'GDP per capita']

for col in cols_to_check_zeros:
    df[col] = df[col].replace(0, np.nan)

print(f"Мінімальна площа: {df['Area'].min()}")
```

```
Мінімальна площа: 2.0
```

Завдання #3:

Побудувати діаграми розмаху та гістограми

Для побудови графіків скористайтесь бібліотекою Matplotlib. Спробуйте погратись з кольорами, розмірами та підписами.

```
import matplotlib.pyplot as plt

# налаштування розміру
fig, axs = plt.subplots(2, 4, figsize=(24, 12))
fig.suptitle('Аналіз розподілу', fontsize=24)

cols = ['GDP per capita', 'Population', 'CO2 emission', 'Area']
colors = ['#5DADE2', '#58D68D', '#EC7063', '#AF7AC5']
titles = ['ВВП на душу населення', 'Населення', 'Викиди CO2', 'Площа']

for i, col in enumerate(cols):
    # діаграми розмаху (boxplots)
    axs[0, i].boxplot(df[col].dropna(), patch_artist=True,
                      boxprops=dict(facecolor=colors[i]),
                      flierprops=dict(marker='o', markerfacecolor='red', markersize=6)) # червоні точки це викиди

    axs[0, i].set_title(f'Розмах: {titles[i]}', fontsize=14)
    axs[0, i].grid(True, linestyle='--', alpha=0.6)

    # гістограми
    axs[1, i].hist(df[col].dropna(), bins=30, color=colors[i], edgecolor='black')
    axs[1, i].set_title(f'Розподіл: {titles[i]}', fontsize=14)
    axs[1, i].grid(True, linestyle='--', alpha=0.6)

plt.tight_layout(rect=[0, 0.03, 1, 0.95])
plt.show()
```

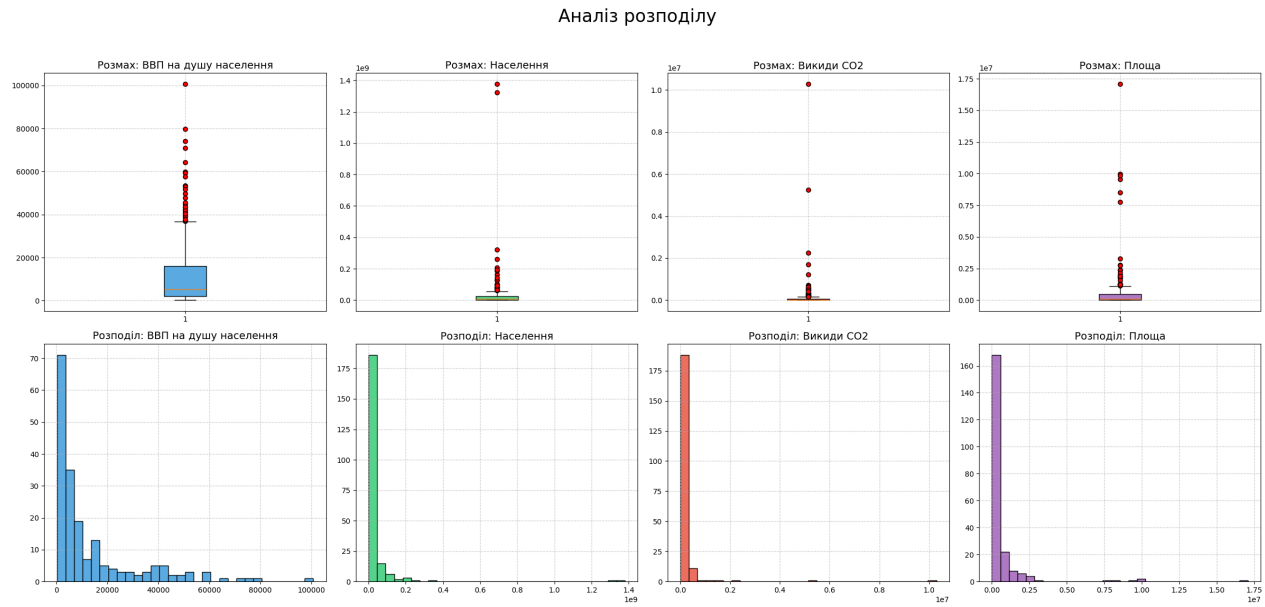

▶ Натисніть тут, щоб побачити підказку

Завдання #4:

Проблема 4. Пропущені значення

Візуалізації з попереднього завдання чітко демонструють, що розподіл даних у всіх числових стовпцях є асиметричним (правостороння асиметрія) і містить значну кількість викидів.

Заповнювати пропуски для ознак GDP per capita, Population, CO2 emission та Area буду медіаною, тому що побудовані графіки показали, що ці дані мають асиметричний розподіл (правосторонню асиметрію) та містять значні викиди. У таких випадках середнє арифметичне дає некоректні, зміщені результати, а медіана є стійкою до викидів і краще відображає реальний центр даних.

```
cols_to_fix = ['GDP per capita', 'Population', 'CO2 emission', 'Area']

for col in cols_to_fix:
    if col in df.columns:
        median_val = df[col].median()
        df[col] = df[col].fillna(median_val)
        print(f"Пропуски в '{col}' заповнено медіаною: {median_val}")
    else:
        print(f"Увага: Стовпець '{col}' не знайдено.")
```

```
Пропуски в 'GDP per capita' заповнено медіаною: 5235.3085465
Пропуски в 'Population' заповнено медіаною: 6221590.5
Пропуски в 'CO2 emission' заповнено медіаною: 9108.828
Пропуски в 'Area' заповнено медіаною: 93030.0
```

Досліджую структуру даних, чи всі пропуски заповнено

```
print(df.isna().sum())
```

```
Country Name      0
Region            0
GDP per capita    0
Population        0
CO2 emission      0
Area              0
dtype: int64
```

Завдання #5:

Додати стовпчик із щільністю населення

Щільність населення розрахую по формулі

$$\text{Population density} = \frac{\text{Population}}{\text{Area}}$$

і додам у новий стовпчик з відповідною назвою.

```
df['Population density'] = df['Population'] / df['Area']
df.head(5)
```

	Country Name	Region	GDP per capita	Population	CO2 emission	Area	Population density
0	Afghanistan	South Asia	561.778746	34656032.0	9809.225	652860.0	53.083405
1	Albania	Europe & Central Asia	4124.982390	2876101.0	5716.853	28750.0	100.038296
2	Algeria	Middle East & North Africa	3916.881571	40606052.0	145400.217	2381740.0	17.048902
3	American Samoa	East Asia & Pacific	11834.745230	55599.0	9108.828	200.0	277.995000

Подальші дії: New interactive sheet

Додаткове завдання:

Дайте відповіді на питання

1. Яка країна має найменшу площу?
2. Знайдіть країну з найбільшою щільністю населення у світі? У Європі та центральній Азії?
3. Яка країна має найбільший ВВП на людину (GDP per capita)?
4. Покажіть топ 5 країн та 5 останніх країн по ВВП на людину.

▶ Натисніть тут, щоб побачити підказку

```
# 1. Яка країна має найменшу площу?
min_area_country = df.loc[df['Area'].idxmin()]
print(f"1. Країна з найменшою площею: {min_area_country['Country Name']} ({min_area_country['Area']} кв.км)")

# 2. Країна з найбільшою щільністю населення
# у світі
max_density_world = df.loc[df['Population density'].idxmax()]
print(f"2a. Найбільша щільність у світі: {max_density_world['Country Name']} ({max_density_world['Population density']

# У Європі та центральній Азії
europe_data = df[df['Region'] == 'Europe & Central Asia']
max_density_europe = europe_data.loc[europe_data['Population density'].idxmax()]
print(f"2b. Найбільша щільність у Європі: {max_density_europe['Country Name']} ({max_density_europe['Population densit

# 3. Яка країна має найбільший ВВП на людину?
max_gdp_country = df.loc[df['GDP per capita'].idxmax()]
print(f"3. Найбільший ВВП на людину: {max_gdp_country['Country Name']} ${max_gdp_country['GDP per capita']:.2f})")

# 4. Топ 5 і останні 5 країн по ВВП
print("\n4. Топ-5 країн за ВВП:")
display(df.nlargest(5, 'GDP per capita')[['Country Name', 'GDP per capita']])

print("\n4. Останні 5 країн за ВВП:")
display(df.nsmallest(5, 'GDP per capita')[['Country Name', 'GDP per capita']])
```

```
1. Країна з найменшою площею: Monaco (2.0 кв.км)
2a. Найбільша щільність у світі: Macao SAR, China (20203.53 чол/кв.км)
2b. Найбільша щільність у Європі: Monaco (19249.50 чол/кв.км)
3. Найбільший ВВП на людину: Luxembourg ($100738.68)

4. Топ-5 країн за ВВП:
```

	Country Name	GDP per capita
115	Luxembourg	100738.68420
188	Switzerland	79887.51824
116	Macao SAR, China	74017.18471
146	Norway	70868.12250
92	Ireland	64175.43824

```
4. Останні 5 країн за ВВП:
```

	Country Name	GDP per capita
31	Burundi	285.727442
119	Malawi	300.307665
134	Mozambique	382.069330
37	Central African Republic	382.213174
118	Madagascar	401.742270

Збережіть дані у новий файл 'clean_data.csv':

```
from google.colab import files

# зберігаємо файл (створюємо його в пам'яті Colab)
df.to_csv('Data2_clean.csv', index=False)

# завантажуємо на комп'ютер
files.download('Data2_clean.csv')
```

Виконала студентка групи ІП-44

Бідюк Марія